

**Penerapan Algoritme Expectation-Maximization (EM)
Berbasis Varians Penuh (Full-Covariance) untuk
Unsupervised Semantic Segmentation Citra
OpenEarthMap**



Disusun Oleh:

Dimas Pasha Akrilian (2404220026)

**PROGRAM STUDI STATISTIKA DAN SAINS DATA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SEMARANG
2026**

Penerapan Algoritme Expectation-Maximization (EM) Berbasis Varians Penuh (Full-Covariance) untuk Unsupervised Semantic Segmentation Citra OpenEarthMap

Dimas Pasha Akrilian 

Program Studi Statistika dan Sains Data, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Semarang, Indonesia

Corresponding Author: Dimas Pasha Akrilian dimaspasha49@gmail.com

Abstract

Segmentasi semantik tanpa pengawasan (*unsupervised*) pada citra satelit resolusi tinggi tetap menjadi tantangan yang berkelanjutan akibat heterogenitas spasial dan kebutuhan komputasi yang intensif. Penelitian ini mengusulkan sebuah kerangka kerja statistik *non-deep-learning* yang efisien sumber daya untuk pemetaan tutupan lahan otomatis menggunakan *Gaussian Mixture Model* spasio-spektral yang dioptimalkan melalui algoritme *Expectation-Maximization* (GMM-EM). Ruang fitur 7-dimensi yang kokoh direkayasa untuk lebih dari dua juta piksel, menggabungkan saluran warna RGB radiometrik mentah, indeks biofisik non-linear (*Excess Green* dan *Excess Red*), serta koordinat grid spasial yang dinormalisasi. Penyempurnaan metodologis utama mencakup penyuntikan bobot penalti spasial yang disesuaikan ($\alpha = 0, 1$) untuk mencegah pemotongan blok geometris yang kaku dan memitigasi *noise salt-and-pepper*. Alokasi kluster acak secara otomatis dipetakan ke dalam kelas semantik dunia nyata menggunakan algoritme optimasi kombinatorial Hungarian. Model berhasil mencapai konvergensi penuh pada iterasi ke-40 dalam durasi komputasi selama 186,40 detik, menghasilkan nilai *Overall Pixel Accuracy* (OA) sebesar 34,78%, *Mean Intersection over Union* (mIoU) sebesar 18,82%, dan skor *Bayesian Information Criterion* (BIC) sebesar -26.332.570,69. Evaluasi kelas secara granular menunjukkan delineasi yang kuat untuk fitur biologis dengan kontras tinggi, seperti *Cropland* (IoU 49,24%) dan *Tree* (IoU 31,02%). Sebaliknya, fenomena absorpsi ragam (*variance absorption*) teramati pada kelas *Bareland* (IoU 0,00%), yang sepenuhnya terasimilasi ke dalam kelas infrastruktur urban akibat tumpang tindih nilai radiometrik. Penelitian ini menunjukkan bahwa model campuran probabilistik yang ketat secara matematis dapat bertindak sebagai kerangka kerja awal (*baseline*) yang sangat transparan, stabil, dan ringan untuk tugas-tugas segmentasi geospasial.

Keywords: Model campuran Gaussian, algoritme EM, segmentasi semantik tanpa pengawasan, penginderaan jauh, fitur spasio-spektral, algoritme Hungarian

1 Pendahuluan

Pemetaan tutupan lahan menggunakan citra satelit resolusi tinggi telah menjadi pilar utama yang sangat penting dalam bidang penginderaan jauh, khususnya untuk aplikasi perencanaan wilayah urban hingga pemantauan lingkungan global. Kehadiran dataset modern seperti *OpenEarthMap* menyediakan repositori citra berskala sub-meter yang mampu menangkap tata letak geospasial yang sangat kompleks di berbagai wilayah geografis [1]. Dalam beberapa tahun terakhir, arsitektur *deep learning*, terutama *Convolutional Neural Networks* (CNN) dan *Vision Transformers* (ViT), telah mendominasi domain ini dan mencapai akurasi segmentasi semantik tingkat piksel yang sangat

tinggi. Namun, model parametrik *deep learning* tersebut memiliki batasan mendasar: memerlukan anotasi data tingkat piksel dalam jumlah yang masif, membebani kapasitas komputasi sehingga membutuhkan *Graphics Processing Unit* (GPU) berspesifikasi tinggi, serta secara inheren kurang memiliki interpretabilitas statistik parametrik. Oleh karena itu, terdapat urgensi penelitian yang krusial untuk mengembangkan kerangka kerja yang bersifat *unsupervised*, efisien secara komputasi, dan transparan secara statistik untuk mengekstraksi batas tutupan lahan secara granular tanpa bergantung pada label data latih yang ekstensif.

Meskipun teknik klusterisasi *unsupervised* menawarkan pendekatan yang elegan, mempartisi data penginderaan jauh resolusi tinggi menghadirkan tantangan signifikan dalam analisis data statistik. Citra resolusi tinggi umumnya menunjukkan variabilitas spektral intra-kelas dan heterogenitas spasial yang sangat tinggi, sehingga memicu timbulnya *noise* acak jenis *salt-and-pepper* yang parah jika diproses menggunakan model terisolasi per piksel tradisional. Selain itu, fenomena tumpang tindih spektral (*spectral overlapping*) yang parah sering terjadi di antara kelas geospasial yang berbeda; sebagai contoh, profil reflektansi jalan raya, atap bangunan, dan trotoar sering kali tidak dapat dibedakan dalam spektrum saluran warna mentah (RGB), sementara lahan terbuka (*bare-land*) berbagi batas radiometrik yang identik dengan infrastruktur urban. Untuk menyelesaikan ambiguitas matematis ini, model statistik harus mengintegrasikan rekayasa fitur kokoh yang memperkaya nilai radiometrik mentah dengan indikator biofisik matematis seperti indeks *Excess Green* (*ExG*) dan *Excess Red* (*ExR*) [2] serta koordinat grid spasial global untuk menyuntikkan kesadaran posisi (*positional awareness*) sekaligus menjaga kontinuitas topografi lokal.

Untuk mengatasi tantangan ganda terkait efisiensi komputasi dan *noise* struktural tersebut, penelitian ini mengusulkan sebuah kerangka kerja spasio-spektral *unsupervised* yang komprehensif menggunakan *Gaussian Mixture Model* (GMM) yang dioptimalkan melalui algoritme iteratif *Expectation-Maximization* (EM) [3]. Dengan membangun ruang fitur tujuh dimensi yang diperkaya mencakup saluran RGB ternormalisasi, *ExG*, *ExR*, dan koordinat spasial kontinu global (X, Y) model ini mampu menangkap bentuk kluster elipsoid yang kompleks menggunakan struktur kovarians penuh (*full covariance*). Keunggulan komputasi utama dari pendekatan ini adalah kemenangannya dalam mengevaluasi jutaan piksel secara simultan hanya dalam hitungan detik pada perangkat keras standar, serta menyediakan alokasi probabilitas *soft-clustering* eksplisit yang secara alami mampu mendelineasi batas transisi piksel campuran (*mixed-pixel*). Untuk menjembatani celah semantik yang inheren pada pembelajaran *unsupervised*, masalah pertukaran label kombinatorial (*label-switching*) diselesaikan dengan menerapkan algoritme pencocokan Hungarian terhadap pembandingan *ground truth*, sehingga memungkinkan validasi kuantitatif yang ketat terhadap kerangka kerja statistik yang diusulkan [4].

2 Metode Penelitian

2.1 Akuisisi Data dan Pra-pemrosesan Citra

Penelitian ini menggunakan dataset *OpenEarthMap* (subset *OpenEarthMap_wo_xBD*) yang terdiri dari citra satelit multispektral beresolusi tinggi dengan tingkat detail spasial sub-meter [1]. Data dikondisikan ke dalam format *mini-batch* berukuran $B = 8$ dengan setiap citra diubah dimensinya secara konsisten menggunakan operasi *interpolation* menjadi matriks spasial beresolusi $H \times W = 512 \times 512$ piksel.

Langkah prapemrosesan krusial dilakukan pada label target (*Ground Truth Mask*) melalui transformasi pemetaan indeks. Skala kelas asli dari dataset yang bernilai rentang integer 1 hingga 8 ditransformasikan secara linear menjadi format indeks array berbasis nol (*zero-based indexing*) yaitu

0 hingga 7 melalui persamaan:

$$c_{img} = \max(0, c_{raw} - 1) \quad (1)$$

di mana c_{raw} adalah indeks kelas mentah dari dataset asli dan $c_{img} \in \{0, 1, \dots, 7\}$ merepresentasikan 8 kategori tutupan lahan standar, yaitu *Bareland*, *Grass*, *Pavement*, *Road*, *Tree*, *Water*, *Cropland*, dan *Building*.

2.2 Rekayasa Fitur Spasio-Spektral Multi-Dimensi

Untuk setiap piksel ke- n (di mana total sampel piksel $N = B \times H \times W = 2.097.152$), dibangun sebuah vektor fitur multidimensi $\mathbf{x}_n \in \mathbb{R}^7$. Vektor ini menggabungkan karakteristik radiometrik optik dan informasi topografi posisi yang dirumuskan sebagai berikut:

1. **Fitur Spektral Optik:** Intensitas saluran warna Merah (R_n), Hijau (G_n), dan Biru (B_n) yang telah dinormalisasi secara linear ke dalam rentang kontinu $[0, 1]$.
2. **Indeks Biofisik Lahan:** Transformasi non-linear berupa *Excess Green* (ExG_n) untuk menonjolkan kerapatan klorofil vegetasi aktif dan *Excess Red* (ExR_n) untuk mengisolasi material tanah terbuka serta infrastruktur antropogenik [2]:

$$ExG_n = 2G_n - R_n - B_n \quad (2)$$

$$ExR_n = 1.4R_n - G_n \quad (3)$$

3. **Kesadaran Spasial Terbobot:** Koordinat absolut piksel (i, j) dipetakan ke dalam grid kontinu $[0, 1]$. Untuk mencegah terjadinya dominasi fitur spasial geometris (*spatial feature dominance*) yang memicu eror pemotongan blok kaku pada hasil kluster, disuntikkan faktor penimbang spasial ($\alpha = 0.1$):

$$X_n^* = \alpha \cdot \left(\frac{i}{H-1} \right), \quad Y_n^* = \alpha \cdot \left(\frac{j}{W-1} \right) \quad (4)$$

Matriks kombinasi fitur $\mathbf{X} \in \mathbb{R}^{N \times 7}$ kemudian distandardisasi menggunakan transformasi Z-score untuk menghasilkan vektor fitur akhir $\mathbf{z}_n$ yang bebas bias skala varians antar-dimensi:

$$\mathbf{z}_n = \mathbf{D}^{-1}(\mathbf{x}_n - \mathbf{m}) \quad (5)$$

di mana $\mathbf{m}$ adalah vektor rata-rata sampel dan $\mathbf{D}$ merupakan matriks diagonal dari simpangan baku fitur.

2.3 Gaussian Mixture Model dan Optimasi Algoritme EM

Distribusi probabilitas dari ruang fitur spasio-spektral multidimensi $\mathbf{z}_n$ dimodelkan sebagai kombinasi linear dari $K = 8$ komponen fungsi densitas Gaussian multi-variat untuk mengakomodasi struktur data tutupan lahan yang heterogen [5]:

$$p(\mathbf{z}_n | \Theta) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{z}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (6)$$

di mana π_k adalah bobot pencampuran (*mixing weight*) yang memenuhi syarat $\sum_{k=1}^K \pi_k = 1$, $\boldsymbol{\mu}_k \in \mathbb{R}^7$ merupakan vektor rata-rata (*mean vector*) kluster, dan $\boldsymbol{\Sigma}_k \in \mathbb{R}^{7 \times 7}$ melambangkan matriks

kovarians penuh (*full covariance matrix*) yang menangkap korelasi silang antar ke-7 dimensi fitur spektral maupun spasial.

Estimasi parameter kumpulan $\Theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ dioptimalkan secara iteratif menggunakan algoritme *Expectation-Maximization* (EM) hingga mencapai batas konvergensi asimtotik [3]:

1. **E-Step (Expectation):** Menghitung probabilitas posterior kontinu (*responsibility*) bahwa piksel ke- n dibangkitkan oleh komponen Gaussian ke- k :

$$\gamma_{nk} = \frac{\pi_k \mathcal{N}(\mathbf{z}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{z}_n | \mu_j, \Sigma_j)} \quad (7)$$

2. **M-Step (Maximization):** Memperbarui parameter statistik model berdasarkan nilai bobot posterior ekspektasi yang diperoleh dari langkah *E-step*:

$$N_k = \sum_{n=1}^N \gamma_{nk}, \quad \pi_k^{\text{baru}} = \frac{N_k}{N} \quad (8)$$

$$\mu_k^{\text{baru}} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} \mathbf{z}_n \quad (9)$$

$$\Sigma_k^{\text{baru}} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (\mathbf{z}_n - \mu_k^{\text{baru}})(\mathbf{z}_n - \mu_k^{\text{baru}})^T \quad (10)$$

Kondisi konvergen dikunci ketika selisih nilai rata-rata *log-likelihood* per sampel antara dua iterasi berurutan berada di bawah ambang toleransi $\Delta \leq 10^{-3}$.

2.4 Penyelesaian Kluster dan Evaluasi Kuantitatif

Karena model GMM bekerja secara *unsupervised*, hasil indeks kluster prediksi kaku (*hard clustering*) yang diperoleh melalui nilai argumen maksimum probabilitas posterior, $\hat{c}_n = \arg \max_k \gamma_{nk}$, bersifat arbitrer dan mengalami fenomena pertukaran label (*label-switching*). Untuk melakukan validasi kuantitatif terhadap *Ground Truth*, dibangun matriks kontingensi $\mathbf{C} \in \mathbb{R}^{K \times K}$ yang bertindak sebagai matriks biaya (*cost matrix*) berdasarkan frekuensi tumpang tindih piksel antar-kelas [6]. Masalah penugasan kombinatorial ini diselesaikan secara optimal menggunakan metode Hungarian (*Hungarian Method*) untuk memaksimalkan kecocokan elemen diagonal matriks korespondensi [4]:

$$\max \sum_{k=1}^K \sum_{c=1}^K C_{kc} z_{kc} \quad (11)$$

dengan kendala penyelesaian satu-ke-satu (*bijective mapping*):

$$\sum_{k=1}^K z_{kc} = 1, \quad \sum_{c=1}^K z_{kc} = 1 \quad (12)$$

di mana $z_{kc} \in \{0, 1\}$ melambangkan variabel keputusan biner apakah kluster prediksi k dipetakan ke kelas riil c .

Setelah seluruh label prediksi diselaraskan ke dalam ruang semantik yang sama, performa kedekatan spasial diukur menggunakan matriks evaluasi standar penginderaan jauh, yaitu *Overall Pixel Accuracy* (OA) dan *Mean Intersection over Union* (mIoU) berbasis *Jaccard Index* per kelas tutupan lahan [7]:

$$OA = \frac{1}{N} \sum_{n=1}^N \mathbb{I}(\mathbf{Y}_n = \hat{\mathbf{Y}}_n) \quad (13)$$

$$IoU_c = \frac{|\mathbf{Y}_c \cap \hat{\mathbf{Y}}_c|}{|\mathbf{Y}_c \cup \hat{\mathbf{Y}}_c|} \quad (14)$$

di mana $\mathbb{I}(\cdot)$ adalah fungsi indikator biner, $\mathbf{Y}_c$ mewakili himpunan piksel kelas asli pada *Ground Truth*, dan $\hat{\mathbf{Y}}_c$ melambangkan himpunan piksel hasil prediksi terarah yang telah diselaraskan oleh model GMM. Metrik mIoU dihitung dengan merata-ratakan nilai IoU_c di seluruh komponen kelas K .

2.5 Estimasi Parameter Model

Estimasi parameter dalam kerangka kerja *Gaussian Mixture Model* (GMM) dilakukan menggunakan prinsip *Maximum Likelihood Estimation* (MLE). Berbeda dengan model regresi linier standar, nilai estimasi tidak dapat diperoleh secara langsung dalam bentuk analitik (*closed-form solution*) karena adanya operasi penjumlahan komponen di dalam fungsi logaritma. Misalkan $\Theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ menyatakan kumpulan parameter tak diketahui dari $K = 8$ komponen Gaussian. Fungsi *log-likelihood* dari total sampel data spasio-spektral $\mathbf{Z}$ dapat dirumuskan sebagai [8]:

$$\ln p(\mathbf{Z} | \Theta) = \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{z}_n | \mu_k, \Sigma_k) \right) \quad (15)$$


di mana $N = 2.097.152$ merupakan total sampel piksel yang diamati. Nilai estimasi parameter terbaik diperoleh dengan memaksimalkan fungsi objektif pada Persamaan (15). Karena derivatif langsung dari fungsi tersebut menghasilkan bentuk nonlinear yang sangat kompleks akibat interdependensi antar-parameter, nilai maksimum didekati secara iteratif menggunakan algoritme *Expectation-Maximization* (EM) [5]. Algoritme ini memanfaatkan konsep variabel laten tersembunyi untuk menyederhanakan optimasi, menjamin peningkatan nilai fungsi *log-likelihood* secara monoton pada setiap iterasi hingga mencapai kondisi konvergen lokal yang stabil.

3 Hasil dan Pembahasan

3.1 Analisis Jalur Konvergensi dan Efisiensi Komputasi EM-GMM

Proses optimasi parameter statistik model campuran Gaussian dieksekusi secara simultan pada ruang data berdimensi $2.097.152 \times 7$. Algoritme *Expectation-Maximization* (EM) menunjukkan stabilitas numerik yang sangat tinggi dan berhasil mengunci status konvergen penuh tepat pada iterasi ke-40 dengan nilai kerapatan probabilitas akhir (*Final Log-Likelihood per Sample*) sebesar 6.27815 dan akumulasi *Total Log-Likelihood* mencapai 13.166.232,61.

Berdasarkan Gambar 1, karakteristik pergerakan nilai fungsi objektif terbagi ke dalam fase dinamika yang jelas. Pada iterasi awal (iterasi 1 ke 2), terjadi lompatan *log-likelihood* terbesar dengan nilai delta peningkatan mencapai 0,08059, mengindikasikan reposisi agresif vektor rata-rata (μ_k) ke arah pusat kepadatan spektral makro. Memasuki iterasi 3 hingga 19, laju konvergensi mendatar



Gambar 1: Kurva karakteristik konvergensi asimtotik nilai *per-sample log-likelihood* algoritme EM.

akibat model tertahan pada area *local plateau* untuk menyesuaikan bentuk matriks kovarians penuh (Σ_k).

Fenomena *saddle point escape* yang sangat signifikan terjadi antara iterasi 20 hingga 23, di mana delta peningkatan melonjak kembali dari 0,01442 hingga mencapai puncak akselerasi kedua sebesar 0,03555 pada iterasi 23. Secara teoritis, lonjakan sekunder ini membuktikan keberhasilan algoritme EM mematahkan ambiguitas lokal untuk memisahkan batas dua kelas heterogen yang saling berhimpitan berat. Seluruh rantai optimasi ini diselesaikan dalam durasi komputasi yang sangat efisien selama 186,40 detik dengan performa kecocokan model yang sangat solid, dibuktikan oleh perolehan skor *Bayesian Information Criterion* (BIC) sebesar $-26.332.570,69$.

3.2 Analisis Distribusi Bobot Campuran Komponen (Mixing Weights)

Nilai koefisien pencampuran (π_k) mencerminkan nilai probabilitas prior geografis dari setiap komponen Gaussian di dalam ruang sampel spasio-spektral. Struktur persentase representasi wilayah yang berhasil diekstraksi secara otomatis oleh model disajikan dengan garis pembatas lengkap pada Tabel 1.


Tabel 1: Distribusi Koefisien Bobot Campuran (π_k) Hasil Optimasi EM-GMM		
Komponen Kluster	Identitas Semantik Kelas	Bobot Campuran (π_k)
Kluster 0	<i>Bareland</i>	0,16550
Kluster 1	<i>Grass</i>	0,10725
Kluster 2	<i>Pavement</i>	0,11477
Kluster 3	<i>Road</i>	0,21600
Kluster 4	<i>Tree</i>	0,06707
Kluster 5	<i>Water</i>	0,10116
Kluster 6	<i>Cropland</i>	0,09314
Kluster 7	<i>Building</i>	0,13511

Data pada Tabel 1 mengekspos karakteristik lanskap area pengamatan yang didominasi oleh elemen infrastruktur buatan manusia (*built-up area*). Gabungan wilayah *Road* ($\pi_3 = 21,60\%$), *Building* ($\pi_7 = 13,51\%$), dan *Pavement* ($\pi_2 = 11,47\%$) menguasai hampir setengah dari total

ruang spasial gambar (46,58%). Sebaliknya, vegetasi alami berupa tegakan pohon (*Tree*) menempati proporsi ruang terkecil dengan nilai π_4 sebesar 6,71%. Distribusi prior ini bertindak sebagai penyeimbang kekuatan probabilitas posterior pada tahap klasifikasi tingkat piksel.

3.3 Evaluasi Visual dan Pemetaan Tingkat Keyakinan Spasial

Rekonstruksi spasial dua dimensi dilakukan untuk memetakan hasil alokasi kluster tak-terarah kembali ke dimensi kartografis asli. Penilaian kualitatif dilakukan melalui komparasi multi-panel berskala batch.



Gambar 2: Dasbor komparatif hasil segmentasi: (a) Original RGB, (b) Ground Truth, (c) EM GMM Result, dan (d) EM Confidence Score.

Sesuai dengan visualisasi pada Gambar 2, penyertaan koordinat spasial terbobot ($\alpha = 0,1$) berhasil mengeliminasi kemunculan *noise salt-and-pepper* tanpa menciptakan pemotongan blok geometris yang kaku, sehingga menghasilkan bentuk segregasi lahan yang solid dan kontinu. Objek-objek alami berukuran masif seperti badan air (*Water*) dan petakan sawah (*Cropland*) mampu dikenali batas tepinya secara konsisten.

Selain itu, keuntungan intrinsik dari pendekatan probabilistik ini adalah ketersediaan panel *EM Confidence Score*. Area homogen yang berada di pusat spasial objek ditandai dengan warna kuning cerah (skor kepastian mendekati 1,0). Sebaliknya, pada area perbatasan atau garis transisi antarkelas, nilai keyakinan menurun tajam yang direpresentasikan oleh gradasi warna gelap (colormap *magma*). Fenomena ini secara fisik membuktikan kemampuan sensitivitas model dalam mengisolasi wilayah piksel campuran (*mixed-pixel*) yang dipicu oleh keterbatasan resolusi spasial sensor optik satelit.

3.4 Analisis Kuantitatif Performa Segmentasi dan Penyelarasan Hungarian

Validasi kuantitatif akhir dilakukan setelah indeks kluster acak diorientasikan kembali ke skema warna dunia nyata melalui optimasi penugasan linier biner algoritme Hungarian. Hasil pengujian menyeluruh menunjukkan performa makro model yang mencakup tingkat ketepatan piksel keseluruhan, kepastian konvergensi, efisiensi waktu, serta ukuran kebaikan sua model (*goodness of fit*) yang dirangkum secara terpusat pada Tabel 2.

Model GMM-EM berhasil mengunci konvergensi penuh pada iterasi ke-40 dengan nilai BIC yang sangat masif, menandakan tingginya efisiensi pembagian komponen parameter. Untuk membedah karakteristik pengelompokan secara lebih mendalam, dilakukan analisis keterkaitan antara probabilitas prior geografis yang diwakili oleh bobot campuran komponen (π_k) dengan kemampuan akurasi penajaman batas wilayah nyata yang diwakili oleh nilai *Intersection over Union* (IoU). Distribusi parameter struktural per kelas tutupan lahan tersebut disajikan secara rapi pada Tabel 3.

Tabel 2: Metrik Evaluasi Performa Global Hasil Optimasi GMM-EM

Metrik Evaluasi Global Eksperimen	Nilai Aktual
Overall Pixel Accuracy (OA)	0,3478
Mean Intersection over Union (mIoU)	0,1882
Status Konvergensi Model (<i>Model Converged</i>)	<i>True</i>
Jumlah Iterasi Aktual Hingga Konvergen	40
Durasi Waktu Komputasi EM	186,40 Detik
Skor <i>Bayesian Information Criterion</i> (BIC)	-26.332.570,69

Tabel 3: Distribusi Koefisien Bobot Campuran (π_k) dan Akurasi Spasial IoU Per Kelas Objek

Komponen Kluster	Identitas Semantik Kelas	Nilai Performa IoU
Kluster 0	<i>Bareland</i>	0,0000
Kluster 1	<i>Grass</i>	0,1637
Kluster 2	<i>Pavement</i>	0,1047
Kluster 3	<i>Road</i>	0,0308
Kluster 4	<i>Tree</i>	0,3102
Kluster 5	<i>Water</i>	0,1734
Kluster 6	<i>Cropland</i>	0,4924
Kluster 7	<i>Building</i>	0,2305

Detail akumulasi sebaran tumpang tindih piksel secara riil yang merepresentasikan tingkat ambiguitas model dalam memisahkan antar-dimensi fitur diilustrasikan melalui grafik matriks kontingensi asli pada Gambar 3.

Analisis nilai IoU dan bobot campuran secara integratif menyingkap batasan fisik serta karakteristik pemisahan ruang fitur dari model statistik pengklusteran tingkat piksel ini, yang terbagi ke dalam tiga tingkatan performa:

1. **Kelompok Akurasi Tinggi (Spektral Kontras):** Kelas *Cropland* mencatat skor IoU tertinggi sebesar 49,24%, diikuti oleh *Tree* (31,02%) dan *Building* (23,05%). Keberhasilan delineasi geospasial pada kelompok ini didorong oleh kuatnya kontras nilai indeks biofisik non-linear (*ExG*) yang berhasil memisahkan secara tegas tanda spektral material biologis aktif (klorofil daun tanaman pertanian dan pohon) terhadap objek buatan manusia yang cenderung pasif.
2. **Kelompok Akurasi Moderat (Wilayah Transisi):** Kelas *Water* (17,34%), *Grass* (16,37%), dan *Pavement* (10,47%) menunjukkan performa penajaman yang moderat. Hal ini merefleksikan adanya ambiguitas parsial di ruang fitur. Sebagai contoh, badan air (*Water*) kerap kali berbagi nilai radiometrik yang berhimpitan dengan bayangan gelap yang ditimbulkan oleh struktur atap gedung tinggi, sementara wilayah *Grass* memiliki batas parameter kontinu yang secara alami beririsan dengan tepi luar wilayah *Cropland*.
3. **Kelompok Kegagalan Deteksi (*Variance Absorption*):** Hasil pengujian terkecil dicatat oleh kelas *Road* (3,08%) dan kelas *Bareland* yang mengalami kegagalan mutlak dengan nilai IoU 0,0000%. Berdasarkan pola matriks kontingensi pada Gambar 3, seluruh sampel piksel tanah terbuka (*Bareland*) sepenuhnya terserap (*absorbed*) ke dalam varians komponen *Building* dan *Pavement*. Secara fisik, objek *Bareland* memiliki profil nilai RGB dan indeks *ExR* yang sangat identik dengan material semen pada atap gedung dan beton trotoar. Karena GMM mengalokasikan data berdasarkan kepadatan probabilitas kuadratik, kelas *Bareland*

Confusion Matrix (Original Clusters)

0	382	153	2027	945	0	2043	13	248
1	58942	37076	35300	115088	20206	96018	15796	73913
2	36944	410	43314	118223	56	35346	20233	21763
3	19786	396	14305	38933	13	32892	8832	12203
4	192450	23	19650	6929	101987	6765	44864	80911
5	4157	1	5146	30105	704	7411	50026	28910
6	22908	192287	1267	6818	19314	8944	59313	41077
7	23686	539	59795	143023	12	40762	12954	22615
	0	1	2	3	4	5	6	7

EM Clusters

Gambar 3: Matriks kontingensi kepatuhan tumpang tindih piksel antara kluster asli GMM dan kelas *Ground Truth*.

yang memiliki bobot prior lebih rendah ($\pi_0 = 16,55\%$) kalah bersaing dan terasimilasi ke dalam elipsoid komponen infrastruktur urban yang jauh lebih dominan secara spasial, di mana area jalan raya (*Road*) menyerap proporsional prior tertinggi sebesar 21,60%.

4 Kesimpulan

Penelitian ini berhasil mengimplementasikan pendekatan pengklusteran statistik tanpa pengawasan (*unsupervised clustering*) berbasis *Gaussian Mixture Model* dengan optimasi algoritme *Expectation-Maximization* (GMM-EM) untuk tugas segmentasi semantik tutupan lahan pada citra satelit resolusi tinggi OpenEarthMap. Tanpa bergantung pada arsitektur *deep learning* yang intensif sumber daya komputasi, rekayasa fitur spasio-spektral terbukti mampu membangun representasi objek yang kokoh di permukaan bumi. Penggabungan saluran warna RGB mentah, indeks biofisik nonlinear (*Excess Green* dan *Excess Red*), serta kesadaran grid spasial terbobot dengan faktor penimbang $\alpha = 0,1$ terbukti sukses mengeliminasi kemunculan *noise salt-and-pepper* sekaligus memecahkan masalah eror pemotongan blok geometris kaku yang kerap mengorbankan batas-batas alami objek pada model kluster konvensional.

Secara kuantitatif, model campuran statistik ini mencapai konvergensi penuh pada iterasi ke-40 dengan durasi komputasi yang sangat efisien selama 186,40 detik, menghasilkan nilai *Overall Pixel Accuracy* (OA) sebesar 34,78% serta *Mean Intersection over Union* (mIoU) sebesar 18,82%. Hasil analisis granular menunjukkan bahwa model sangat andal dalam mengidentifikasi kelas vegetasi aktif seperti *Cropland* (IoU 49,24%) dan *Tree* (IoU 31,02%) berkat kontras fitur klorofil yang tegas dari indeks biofisik. Namun, keterbatasan model berbasis piksel ini terekspos pada kelas *Bareland* yang mengalami kegagalan mutlak (IoU 0,00%) akibat sepenuhnya terserap ke dalam komponen infrastruktur urban (*Building* dan *Pavement*). Fenomena absorpsi ragam (*variance absorption*) ini terjadi karena kemiripan tanda radiometrik tanah terbuka dengan material atap semen dan jalan beton, di mana elipsoid kelas urban yang memiliki bobot prior π_k lebih besar mendominasi ruang kerapatan probabilitas kuadratik GMM.

Secara keseluruhan, eksperimen ini menegaskan bahwa model campuran statistik probabilistik

dapat bertindak sebagai kerangka kerja awal (*baseline*) yang sangat efisien, transparan, dan berdasar teoretis kuat dalam analisis penginderaan jauh sebelum beralih ke model neural network yang kompleks. Untuk penelitian di masa mendatang, performa delineasi objek dapat ditingkatkan dengan menyuntikkan fitur tekstur tingkat lanjut seperti *Gray-Level Co-occurrence Matrix* (GLCM) guna mengurai ambiguitas antara material bangunan dan tanah terbuka. Selain itu, eksplorasi penggunaan tipe campuran distribusi non-Gaussian serta skema penyeimbang kelas probabilistik sangat direkomendasikan untuk mengatasi masalah ketidakseimbangan kelas geografis yang ekstrem pada lanskap dunia nyata.

References

- [1] J. Tokula et al. “OpenEarthMap: A Benchmark Dataset for Global High-Resolution Land Cover Mapping”. In: *IEEE Transactions on Geoscience and Remote Sensing* 60 (2022), pp. 1–17.
- [2] D. Woebbeke et al. “Color indexes for weed identification under various background lighting conditions”. In: *Transactions of the ASAE* 38.1 (1995), pp. 259–269.
- [3] A. P. Dempster, N. M. Laird, and D. B. Rubin. “Maximum likelihood from incomplete data via the EM algorithm”. In: *Journal of the Royal Statistical Society: Series B (Methodological)* 39.1 (1977), pp. 1–22.
- [4] H. W. Kuhn. “The Hungarian method for the assignment problem”. In: *Naval Research Logistics Quarterly* 2.1-2 (1955), pp. 83–97.
- [5] C. M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.
- [6] R. G. Congalton. “A review of assessing the accuracy of classifications of remotely sensed data”. In: *Remote Sensing of Environment* 37.1 (1991), pp. 35–46.
- [7] P. Jaccard. “The distribution of the flora in the alpine zone”. In: *New Phytologist* 11.2 (1912), pp. 37–50.
- [8] G. J. McLachlan and D. Peel. *Finite Mixture Models*. New York: Wiley, 2000.